

## SVM (Support Vector Machine)

SVM은 샘플의 특성으로부터 모델링하고  
결정 경계를 찾는 방식이 아닌, 결정경계  
자체에 초점을 맞춤.

결정경계는 차원에 따라 폭이 넓어지지만  
선형 선형성이 이를 호평면이라고 칭함.

SVM은 호평면과 Support Vector와의 거리인  
margin을 최대화 하고자 함. 정확히는  
모든 차원에 있어 호의 변이 최대화되는  
방향으로 호평면을 찾음.

→ maximize  $M$ .

$$y_i (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M \quad \forall i = 1, \dots, n$$

→ 샘플을 구분하기 위한 제약조건 있음.

$$\sum_{j=1}^p \beta_j^2 = 1.$$

## 소프트 마진과 하드 마진

하드 마진의 경우 적절한 결정경계를 찾을 수  
없을 경우 있음.



소프트 마진은 일부의 예외를 용인하는 개념으로  
잘못 분류된 샘플에 대해서는 벌을 매긴다.

소프트 마진이 최적화 공식은 아래와 같음

→ maximize  $M$

$$y_i (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M (1 - \epsilon_i),$$

$$\epsilon_i \geq 0, \sum_{i=1}^n \epsilon_i \leq C$$

→ 즉  $C$ 에 의해 허용할 수 있는 마진 갯수로  
조절할 수 있음.

( $C$ 가 커질수록 모델의 유연성은  
증가함.)

## SVM에서 비선형 결정경계

고차원으로 도입하여 비선형성을 표현할 수 있으며  
실제로 고차원으로 만드는 방법보다는 커널을  
사용하여 일반화 함.

SVM은  $\gamma(x)$ 를 최소화하는 최적의 모델이  
모든 샘플로 고차원으로 투영 시키는 방법 대신  
중첩  $x_1, x_2, x_3$  등으로 중첩된 효과를 찾을 수 있음.

→ Linear kernel

$$K(x_i, x_j) = \sum_{r=1}^p x_{ir} x_{jr}$$

내부 곱셈만으로 커널을 구현함.

→ Polynomial kernel

$$K(x_i, x_j) = (1 + \sum_{r=1}^p x_{ir} x_{jr})^d$$

내부 곱셈에 고차원으로 도입하는 개념으로서  
 $d$ 에 따라 유연성이 결정됨.

→ Radial kernel (가우시안 커널)

$$K(x_i, x_j) = \exp(-\gamma \sum_{r=1}^p (x_{ir} - x_{jr})^2)$$

두 벡터에 대해 유클리드 거리를 구하고,  
감마( $\gamma$ )를 곱해 자승의 음의 표현함.  
가장 많이 사용되며, 감마에 의해서  
유연성이 결정됨.